

Pi_CMC MLP 模型报告

MLP 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_mlp_20260806_182308
调参日志	runs\Pi_CMC\Pi_CMC_mlp_tuning_20260806_174258\train.log
运行时间	调参 17:42 ~ 18:23 (约 41 分钟), 最终训练 18:23 (数秒)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

MLP (多层感知机) 是 10 个模型中唯一的**前馈全连接深度网络** (RNN/Transformer 为序列式深度模型)。架构为 Linear $\rightarrow$ BatchNorm $\rightarrow$ GELU $\rightarrow$ Dropout 重复堆叠 N 层, 末层映射到单值输出, 以 522 维特征向量整体作为输入 (不做序列化)。深度网络对特征的**非线性组合与隐式高阶交互**建模能力强于树模型, 是“手工特征 + 神经网络”路线的代表。

在 Pi_CMC 任务中, MLP 的 Test $R^2 = 0.5402$ 、Test RMSE = 4.8837, 在 10 个模型中**排名第 8**。虽然仍是深度模型中的最优者 (显著优于 RNN/Transformer), 但相对树模型明显落后——Pi_CMC 的小样本 (552 训练) 使深度网络的过拟合风险放大。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载，与其余模型一致。
- **数据规模**：训练池 631 条（552 训练 + 79 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner）。这是深度模型中唯一使用 Optuna 的（RNN/Transformer 用固定架构）。

最优试验（Trial 25, CV RMSE = 3.6857）：

参数	值
n_layers	6
hidden_dim	143
dropout	0.088
activation	gelu
learning_rate	0.00203
weight_decay	8.97e-6
batch_size	49
Best CV RMSE	3.6857

调优过程观察： - 最优解偏好**6 层深堆叠 + 较小隐藏层（hidden_dim=143） + GELU 激活 + 低 dropout（0.088）**，学习率收敛到 0.002 的量级。 - 后续试验（Trial 42~48）CV RMSE 稳定在 3.71~3.77，与最优解差距 < 0.08，说明搜索已收敛、解稳定；50 轮中约 20 轮被剪枝。 - 值得注意的是，MLP 的 **CV RMSE（3.6857）在 10 个模型中最低**，甚至优于榜首 XGBoost（4.0309）——但最终测试表现（4.8837）却显著恶化，说明小样本下 MLP 的 CV 优势未能泛化到测试集，这正是深度模型在本任务的根本困境。

训练过程

最终模型以最优参数在 552 条数据上训练，**早停在 epoch 280** 触发。训练约 280 个 epoch 表明网络需要较多迭代才能收敛；由于早停机制，最终以验证最优权重（而非末轮权重）作为交付模型。但验证集 RMSE（4.1786）与最终测试

RMSE (4.8837) 之间存在明显差距，提示**测试分布与训练分布存在一定偏移**，深度网络对该偏移的鲁棒性弱于树模型。

说明：最终训练与调参在不同运行中执行（调参日志在 `Pi_CMC_mlp_tuning_20260806_174258`，本次为最终训练运行）。

测试结果

指标	值
Test RMSE	4.8837
Test MAE	3.3190
Test R ²	0.5402
Best CV RMSE	3.6857
Best val RMSE	4.1786

说明：本次 MLP 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用 `train_mlp_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test MSE = 23.8501 与之印证。MLP 的 Test RMSE (4.8837) 显著高于调参 CV (3.6857，差距约 32%) 与验证 RMSE (4.1786)，是树模型中常见的“测试优于 CV”现象的**反向版本**——深度网络在小样本 + 固定随机种子划分下的泛化稳定性明显不足。

特征重要性

MLP 为黑盒网络，日志未输出特征重要性。其输入为 522 维原始特征向量，重要特征需借助 **SHAP 的 KernelExplainer** 事后归因。基于其余树模型的一致性结论，可推断其预测主要由**原子聚合统计（Gasteiger 电荷类）与分子尺寸/疏水性描述符**驱动——这正是 XGBoost/CatBoost/HistGB 等模型共同指向的 Pi_CMC 主导特征。MLP 的 6 层深网络能隐式组合这些特征，但受限于样本量，未能像树模型那样稳定捕捉其规律。

结论与评价

优点： - **深度模型中的最优者：** $R^2 = 0.5402$ ，显著优于 RNN (-0.0315) 与 Transformer (-0.0663)。 - 使用 Optuna 充分调参 (vs 固定架构的 RNN/Transformer)，超参选择有依据；CV RMSE (3.6857) 为全模型最低，说明在训练分布内部建模能力很强。 - 早停 + Dropout + weight_decay 三重正则。

不足： - **泛化失败：** Test RMSE (4.8837) 比 CV (3.6857) 恶化 32%，排名第 8，被全部树模型反超——小样本 (552) 下深度网络的过拟合与测试分布偏移问题暴露无遗。 - 调参成本高 (约 41 分钟)，为树模型的数十倍。 - 黑盒模型，可解释性差；不提供不确定性估计 (对比 NGBoost)。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R^2
6	HistGB	4.5919	0.5935
7	RandomForest	4.7542	0.5642
8	MLP	4.8837	0.5402
9	RNN	7.3144	-0.0315
10	Transformer	7.4369	-0.0663

MLP 处于深度模型与树模型的分界点上：虽然显著优于另两个深度模型 (RNN/Transformer)，但在 Pi_CMC 上完全无法匹敌第一梯队树模型 (XGBoost/CatBoost, $R^2 \approx 0.64$)。在 522 维手工特征 + 552 训练样本的配置下，**深度网络路线在 Pi_CMC 上的性价比不敌树模型**；若坚持深度路线，需扩充数据或改用更强的特征自学习架构。