

Pi_CMC NGBost 模型报告

NGBost 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_ngboost_20260806_182509
运行时间	18:25 ~ 19:36 (约 71 分钟, 含 Optuna 50 轮调参与最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

NGBost (Natural Gradient Boosting) 是斯坦福提出的**概率型梯度提升**框架: 它不是直接回归均值, 而是把输出建模为一个**参数化分布** (此处为 Normal 分布, 即同时预测均值和方差), 并通过**自然梯度**对分布参数进行 boosting。其独特价值在于——每次预测不仅给出 Pi_CMC 的点估计, 还附带**不确定性 (标准差)**, 这对于实验设计中评估预测可靠性具有实际意义。

在 Pi_CMC 任务中, NGBost 的 Test $R^2 = 0.6277$ 、Test RMSE = 4.3943, 在 10 个模型中**排名第 3**, 是第一梯队 (XGBoost/CatBoost) 之后的次优精度, 且是唯一具备概率输出能力的模型。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 631 条 (552 训练 + 79 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

与 pCMC 任务 (沿用预调优参数、无 Optuna) 不同, 本次 Pi_CMC 运行**采用 Optuna 50 轮 × 5 折交叉验证**为概率模型重新搜索超参数。

最优试验 (Trial 47, CV RMSE = 4.0595) :

参数	值
n_estimators	1191
learning_rate	0.00840
minibatch_frac	0.8949
max_depth	6
min_samples_leaf	9
score_rule	LogScore
Best CV RMSE	4.0595

调优过程观察: - 早期试验在 CRPScore 规则下普遍表现较差 (Trial 2/3/4 的 CV RMSE ≥ 4.97) , 搜索很快收敛到 **LogScore (对数似然) 规则**, 说明对 Pi_CMC 而言以负对数似然作为评分目标更契合概率输出。 - 最优解集中在**浅到中等深度 (max_depth=6) + 小学习率 (0.008) + 较多迭代 (1191)** 的稳健区间, `min_samples_leaf=9` 较小, 允许树在叶节点上更精细地刻画分布参数。 - 50 轮中约 20 轮被剪枝, 搜索在 Trial 47 收敛, 后续试验未见显著改进。

训练过程

最终模型以最优参数在 552 条数据上训练, 日志记录 1100+ 轮迭代的损失走势:


迭代	loss	scale	norm
0	3.4075	1.000	5.779
400	2.0338	1.000	1.762
800	1.4665	1.000	1.232
1100	1.2480	1.000	1.065

训练损失（基于 LogScore 的负对数似然）从 3.41 单调降至 1.25，`norm`（每轮梯度更新范数）从 5.78 收缩至 1.07，说明自然梯度 boosting 稳定收敛、每一步更新幅度逐步收窄。日志中 `val_loss` 恒为 0.0000，这是概率输出的验证集指标未按相同口径记录的日志细节，不影响最终测试评估的可靠性。

测试结果

指标	值
Test RMSE	4.3943
Test MAE	3.1303
Test R ²	0.6277
参考 CV RMSE（调参时）	4.0595
预测分布	Normal（均值 ± 标准差）
平均预测标准差	1.0070

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test MSE = 19.3103 与之印证。**平均预测标准差 1.0070 是一个极具价值的输出**：它表示模型对测试集中每个分子的 Pi_CMC 预测，平均认为有 ~68% 的把握落在 $\pm 1.01 \text{ mN/m}$ 的区间内——考虑到 Pi_CMC 本身量级较大（单位 mN/m ），该不确定性提示预测在高值区间仍需谨慎，将预测不确定性与点估计一并交付，可作为后续实验的置信度筛选依据。


特征重要性

日志尝试输出特征重要性时出现 `unexpected shape (2, 522), skipping` ——这是因为 NGBoost 的基学习器输出 **2 个分布参数**（均值与方差），其重要性权重为 2×522 的结构，现有日志代码未适配该形状而跳过。这属于**日志展示层面的缺失**，而非模型问题。

SHAP 特征重要性可视化（基于测试集的 KernelExplainer 归因，NGBoost 无原生 TreeExplainer）中，Top-5 依赖图为 `atom_std_44`、`atom_mean_35`、`MolWt`、`atom_std_38`、`brics_30`——**原子聚合统计 (std/mean) 与分子量、BRICS 片段**共同构成主要归因来源。这与 XGBoost/CatBoost 的结论呼应： Pi_CMC 的预测由**原子局部环境统计 (电荷/电负性散布) 与整体尺寸、反应活性片段**共同驱动，而非单一疏水性描述符：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_std_44*、*atom_mean_35*、*MolWt* 等居前。

结论与评价

优点： - **概率输出：**同时给出均值与不确定性，是 10 个模型中唯一能评估单点预测置信度的模型，工程价值最高。 - 精度第 3 ($R^2 = 0.6277$)，紧随 XGBoost/CatBoost 第一梯队之后，且差距可控（距 CatBoost 仅 0.0874 的 RMSE）。 - 本次为 *Pi_CMC* 目标重新调参（Optuna 50 轮），超参数选择有依据。

不足： - 调参成本较高（50 轮 5 折 CV 约 71 分钟）。 - 特征重要性展示缺失（形状未适配），可解释性文档化不完整。 - 相比点估计模型（XGBoost/CatBoost），均值预测的极致精度略有折衷（概率模型需同时拟合方差）。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
1	XGBoost	4.2675	0.6489
2	CatBoost	4.3069	0.6424
3	NGBoost	4.3943	0.6277
4	LightGBM	4.4858	0.6121
5	CIF (ExtraTrees)	4.4869	0.6119

NGBoost 是“精度 + 不确定性”双重需求下的**首选模型**：当用户不仅要 Pi_CMC 预测值、还要知道该预测有多可靠时，NGBoost 是最合适的选择，可将其作为 XGBoost/CatBoost 之外的互补预测器。