

Pi_CMC RandomForest 模型报告

RandomForest 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_rf_20260806_193704
运行时间	19:37 ~ 19:39 (约 2 分钟, 含 Optuna 50 轮调参与最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

随机森林 (Random Forest) 是 Breiman 提出的 **Bagging + 随机特征子集集成** 方法: 每棵树在自助采样子集上训练, 每次分裂仅考虑 `max_features` 个随机特征, 最终取多棵树平均。它对特征尺度不敏感、天然抗过拟合, 是 522 维高维稀疏特征下的稳健基线模型。本项目使用 Optuna 50 轮 $\times$ 5 折交叉验证搜索 `n_estimators` / `max_depth` / `min_samples_split` 等关键超参。

在 Pi_CMC 任务中, RandomForest 的 Test $R^2 = 0.5642$ 、Test RMSE = 4.7542, 在 10 个模型中**排名第 7**, 位于第二梯队后段。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 631 条 (552 训练 + 79 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 44, CV RMSE = 4.1658) :

参数	值
n_estimators	1368
max_depth	24
min_samples_split	7
min_samples_leaf	1
max_features	sqrt
bootstrap	False
Best CV RMSE	4.1658

调优过程观察: - 最优解偏好深树 (**depth=24**) + **sqrt 特征采样** ($\sqrt{522} \approx 23$) + **bootstrap=False** (**全样本训练**) ——即用“每树看全样本 + 随机列子集”代替传统 bagging 的行采样, 在 552 样本的小数据上最大化每棵树的利用率。 - 早期试验 (Trial 0/1) CV RMSE 高达 5.7/5.0, 搜索通过减小 min_samples_leaf 与加深树收敛到 4.17 附近; Trial 42~49 稳定在 4.17~4.22, 搜索收敛。 - 50 轮中约 15 轮被剪枝, 每轮 5 折 CV 耗时约 1~3 秒, 整个调参仅约 2 分钟。


训练过程

- **调参阶段**: 50 轮 Optuna 内每轮 5 折 CV, CV RMSE 从 Trial 0 的 5.7302 收敛至 Trial 44 的 **4.1658**。
- **最终训练**: 以最优参数 (1368 棵树) 在 552 条训练集上一次性训练完成, 无早停机制 (随机森林无迭代式早停) , 随后直接进行测试评估。

测试结果

指标	值
Test RMSE	4.7542
Test MAE	3.2180
Test R ²	0.5642
参考 CV RMSE (调参时)	4.1658

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.7542) 高于调参 CV (4.1658)，存在明显的测试-调参差距，说明深树全样本训练 (bootstrap=False) 在小样本上有一定过拟合倾向。Test MSE = 22.6026 与之印证。RandomForest 的 R² = 0.5642 位列第 7，被同族的 CIF (ExtraTrees, R² = 0.6119) 反超。

特征重要性 (Top 20)

日志输出的 Top-20 特征重要度数值均为 0.0 (sklearn 重要性取整展示口径问题)，但排序仍指示特征分布：前四均为**原子聚合统计** (atom_std_44、atom_mean_44、atom_mean_4、atom_std_11)，其后为 atom_std_38、atom_std_4、atom_std_40 与 **键级聚合** (bond_std_12、bond_mean_3、bond_mean_12、bond_std_4)。

Top-5 编号列表 (取自日志 Top 20)：


1. **atom_std_44** —— 原子特征聚合 (标准差)
2. **atom_mean_44** —— 原子特征聚合 (均值)
3. **atom_mean_4** —— 原子特征聚合 (均值)

4. **atom_std_11** —— 原子特征聚合（标准差）


5. **atom_mean_11** —— 原子特征聚合（均值）

物理分析：与 HistGB 相似，RandomForest 的重要性集中于**原子与键级聚合统计**，**atom_44**（Gasteiger 电荷类）与 **atom_11**（氢键相关）的入选提示**电荷分布与氢键能力**对 Pi_CMC 起主导作用——表面压取决于极性头基在界面的取向与相互作用，电荷/氢键特征正是这种相互作用的直接表征。

SHAP 分析（TreeExplainer）给出的 top-5 依赖图为 atom_mean_35、bond_std_12、atom_std_44、atom_mean_11、bond_mean_3，与排序大致呼应：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_mean_35*、*bond_std_12*、*atom_std_44* 靠前。

结论与评价

优点： - **训练极快**（约 2 分钟），且无调参迭代早停，是 10 个模型中成本最低之一。 - 对特征尺度不敏感、无需归一化，随机子采样天然抗噪声，模型稳定可复现。 - 精度第 7 ($R^2 = 0.5642$)，作为高维手工特征下的稳健基线可用。

不足： - 相对第一梯队 (XGBoost/CatBoost) 有约 0.45~0.49 的 RMSE 差距，未进入 $R^2 \approx 0.64$ 梯队。 - 测试-调参差距 (4.7542 vs 4.1658) 偏大，深树 + bootstrap=False 在 552 样本上有过拟合倾向。 - 被同族的 CIF (ExtraTrees) 显著反超 (R^2 差 0.048)，说明在此任务上 ExtraTrees 的“随机阈值 + 全特征”策略优于随机森林的“列子采样”策略。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R²
5	CIF (ExtraTrees)	4.4869	0.6119
6	HistGB	4.5919	0.5935
7	RandomForest	4.7542	0.5642
8	MLP	4.8837	0.5402
9	RNN	7.3144	-0.0315

RandomForest 位于第二梯队后段。若在该族模型中择优，应优先 **CIF (ExtraTrees)** ——同族更强且训练成本相近；RandomForest 更适合作为强调稳健可复现的基线。