

Pi_CMC RNN-LSTM 模型报告

RNN (LSTM) 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_rnn_20260806_194102
运行时间	19:41 ~ 19:44 (约 3 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RNN 使用 **3 层 LSTM** 处理 522 维特征向量。本项目对深度序列模型有一个特殊设计：**将 522 维特征向量重塑为 (batch, 522, 1)，即把每个特征维度当作一个时间步、逐维送入 LSTM** (Deep models treat 522-dim vector as sequence)。LSTM 因此沿“特征轴”顺序读取 522 个时间步，最终隐藏状态经线性层映射为 Pi_CMC。

这一设计的前提是**特征维度之间存在可被顺序建模的“序列依赖”**。但 522 维 PharmHGT 特征由原子聚合、键聚合、MACCS、BRICS、头尾比、描述符等**异构模块拼接**而成，维度间并无自然的时序关系——这是 RNN 在本任务中失效的结构性原因。

在 Pi_CMC 任务中，RNN 的 Test $R^2 = -0.0315$ 、Test RMSE = 7.3144，在 10 个模型中**排名第 9**（倒数第二）。 R^2 为负意味着预测劣于“直接预测均值”的基线，模型**完全失效**。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载（ [Cache HIT] ），与其余模型一致。
- **数据规模**：训练池 631 条（552 训练 + 79 验证），测试集 70 条。
- **数据划分**： `train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

RNN 使用**固定架构，不经过 Optuna**：

参数	值
LSTM 层数	3
hidden_dim	64
dropout	0.2
激活	relu (LSTM 内部)
learning_rate	1e-3
weight_decay	1e-5
batch_size	32
训练轮数	800

固定超参意味着模型容量与训练策略未针对 Pi_CMC 优化，hidden_dim=64 对 522 维输入而言容量偏小。

训练过程

日志记录了每 50 轮的验证 RMSE，**训练曲线近乎水平、毫无收敛迹象**：

Epoch	Val RMSE	best
50	7.3810	7.3810
100	7.2435	7.2355
200	7.2417	7.2325
300	7.2335	7.2319
400	7.2365	7.2306
500	7.2371	7.2222
600	7.2237	7.2222
700	7.2466	7.2222

Early stopping at epoch 745, best val RMSE = 7.2222。

关键观察： - 从 epoch 50 到 700，验证 RMSE **始终在 7.22~7.38 的狭窄区间内波动**，best 仅从 7.3810 微降到 7.2222——模型在整个训练过程中几乎没有任何有效学习。 - 验证 RMSE ≈ 7.22 恰与“用训练集均值预测”的基线误差相当（Pi_CMC 的标准差量级即 ~ 7 ），说明 LSTM **实质上退化为输出近似常量的模型**。 - 这意味着在 552 条小样本上，3 层 LSTM 无法从 522 个“伪时间步”中提取任何有意义的特征间依赖，梯度信号不足以驱动有效收敛。

测试结果

指标	值
Test RMSE	7.3144
Test MAE	5.7415
Test R^2	-0.0315
Best val RMSE	7.2222

说明：本次 RNN 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用缓存特征另行绘制。

Test RMSE (7.3144) 与 best val RMSE (7.2222) 几乎相同，且 **Test R^2 为负 (-0.0315)** ——这是决定性的失效信号：模型的预测精度连“永远预测训练集均值”都不如。Test MSE = 53.5010 为全模型最高之一，MAE = 5.7415 同样垫

底。

特征重要性

LSTM 为黑盒循环网络，日志无特征重要性输出。其“逐维读入”的机制使每个特征维度等价地参与时序传播，**无法区分特征主次**——与树模型明确指向的原子聚合/药效团特征形成对比。鉴于模型整体失效 ($R^2 < 0$)，对其进行特征级归因的意义不大。

结论与评价

优点： - 训练快（约 3 分钟），作为“序列化 522 维特征”路线的对照实验，成本低。

不足： - **完全失效：** Test $R^2 = -0.0315$ （负值），预测劣于均值基线，是 10 个模型中仅有的两个负 R^2 模型之一。 - 训练曲线 745 轮近乎水平、best val 仅从 7.38 微降到 7.22，几乎无有效学习，实质退化为输出近似常量。 - **特征维度无自然时序关系**，LSTM 的序列假设与本任务特征结构不匹配，是失效的结构性原因。 - 小样本（552）+ 固定小容量架构（hidden=64）进一步恶化学习能力。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
7	RandomForest	4.7542	0.5642
8	MLP	4.8837	0.5402
9	RNN	7.3144	-0.0315
10	Transformer	7.4369	-0.0663

RNN 与 Transformer 是仅有的两个 $R^2 < 0$ 的模型，构成“深度序列模型完全失效”组。对比同为深度模型的 MLP ($R^2 = 0.5402$) 仍可学到有效信息，说明问题不在“神经网络”本身，而在**强行把 522 维扁平特征序列化**这一策略。本项目的方法论结论明确：**手工特征 + 深度模型的正确组合是 MLP 式全连接（直接建模特征间非线性），而非 LSTM 式序列化**。RNN 定位为方法学对照，不推荐作为 Pi_CMC 的生产预测器。