

Pi_CMC Transformer 模型报告

Transformer 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_transformer_20260806_195418
运行时间	19:54 ~ 20:14 (约 20 分钟, 315 轮训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

Transformer 采用 **3 层 Transformer Encoder** ($d_{\text{model}}=128$ 、4 头注意力、FFN 256、GELU 激活), 与 RNN 相同, 将 522 维特征向量重塑为 (batch, 522, 1) 的序列输入, 通过**自注意力机制**建模特征维度间的依赖关系, 末层池化后映射为 Pi_CMC。训练使用 CosineAnnealingLR 学习率调度与梯度裁剪。

在 Pi_CMC 任务中, Transformer 的 Test $R^2 = -0.0663$ 、Test RMSE = 7.4369, 在 10 个模型中**排名最末** (第 10), 且是 R^2 为负的两个模型之一——预测劣于“直接预测均值”的基线, 模型**完全失效**。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 631 条 (552 训练 + 79 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

Transformer 使用**固定架构, 不经过 Optuna**:

参数	值
d_model	128
Encoder 层数	3
注意力头数	4
FFN 维度	256
激活	GELU
dropout	0.1
learning_rate	1e-3
weight_decay	1e-5
batch_size	16
调度器	CosineAnnealingLR

固定超参 + 小 batch (16) , 整体容量与训练策略均未针对 522 维小样本优化。

训练过程

日志记录了每 5 轮的验证 RMSE, **训练曲线近乎水平、毫无学习迹象**:

Epoch	Val RMSE	best
5	7.2036	7.2036
20	7.2031	7.2031
60	7.2491	7.2031
100	7.3216	7.2031
200	~7.20	7.2027
300	7.2871	7.2027

Early stopping at epoch 315, best val RMSE = 7.2027。

关键观察： - 从 epoch 5 到 315，验证 RMSE **始终在 7.20~7.32 的狭窄区间内波动**，best 仅从 7.2036 微降到 7.2027——模型在 300 余轮训练中几乎没有学到任何有效信息。 - 验证 RMSE ≈ 7.20 恰与“用训练集均值预测”的基线误差相当（Pi_CMC 的标准差量级即 ~ 7.2 ），说明 Transformer **实质上退化为输出近似常量的模型**。 - 即便训练约 20 分钟（315 轮），自注意力机制也未能从 522 个“伪时间步”中提取任何有意义的特征依赖，与 RNN 的表现如出一辙。

测试结果

指标	值
Test RMSE	7.4369
Test MAE	5.8167
Test R ²	-0.0663
Best val RMSE	7.2027

说明：本次 Transformer 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用缓存特征另行绘制。

关键信号：Test R² 为负（-0.0663）且 Test RMSE (7.4369) 劣于 Best val RMSE (7.2027) ——这是决定性的失效信号，模型的预测精度连“永远预测训练集均值”都不如，且测试表现差于验证，泛化完全失败。Test MSE = 55.3081 为全模型最高，MAE = 5.8167 同样垫底。

特征重要性

Transformer 依赖注意力权重，但日志未输出注意力归因。其自注意力会为 522 个特征维度计算两两关联，理论上可做可解释性分析 (attention rollout)，但本项目未生成相应图。鉴于模型整体失效 ($R^2 < 0$)，其特征级解释的参考价值有限。

结论与评价

优点： - 作为注意力机制的探索性 baseline，与 RNN 一起验证了“序列化 + 自注意力”路线在本任务的**不适用性**，为后续方法选择提供了明确的反面证据。

不足： - **性能垫底：** $R^2 = -0.0663$ 为全模型最低，且唯一测试劣于验证（除同为失效的 RNN 外），泛化完全失败。 - 训练曲线 315 轮近乎水平、best val 仅从 7.20 微降到 7.20，几乎无有效学习，实质退化为输出近似常量。 - 与 RNN 相同的结构性问题：522 维异构特征**无自然序列关系**，自注意力建模的“依赖”缺乏物理意义；而 Transformer 参数量大、对 522 条小样本更容易失效。 - 固定超参未优化，小 batch + 大模型加剧了不稳定性，训练成本（约 20 分钟）与收益严重失衡。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
8	MLP	4.8837	0.5402
9	RNN	7.3144	-0.0315
10	Transformer	7.4369	-0.0663

方法论结论： 三个深度模型（MLP 0.5402 / RNN -0.0315 / Transformer -0.0663）的排序清晰地说明——对 522 维 PharmHGT 扁平特征，**全连接 (MLP) $\gg$ 循环 (LSTM) $\gg$ 注意力 (Transformer)**。Transformer 的强项在于长程依赖与大规模预训练，而本任务样本量小、特征维度排列无时序意义，恰恰落在其能力盲区。**Transformer 应被排除出本项目的生产预测方案**；若未来引入图结构 (AttentiveFP) 或大分子表示，方可重新评估注意力路线的价值。